前言：

本报告以国泰航空（Cathay Pacific）作为研究对象，并假设叙述人以公司首席财务官（Chief Financial Officer, CFO）的视角出发。报告希望评估开发额外行李保障产品的商业可行性，并为行李处理异常可能带来的赔偿成本及旅客的额外经济损失这一议题设计了一套具有一定可行性的行李保障方案，旨在改善旅客出行体验的同时为航空公司探索新的额外收入来源。

报告给定的保险方案初步面向国泰航空从香港出发的直飞航班，为符合条件的旅客提供“额外行李保障产品”这一服务。我们假设用户可以在 Cathay Pacific 的应用程序中购买该产品，且用户的请求都可以得到恰当的回应和支持。（即假设国泰已经具备产品销售、客户服务和理赔支持渠道。）

由于无法直接获取国泰航空内部的行李处理及保险索赔记录，我们采用美国航空运输统计局（BTS）的公开数据开展风险预测实验，并通过概率模型及财务模拟评估保障方案的可行性。

1. Introduction

在现代航空产业中，航空行李运输是保证旅客体验、增进运输效率的重要组成部分之一。随着航空运输量的持续增长，航空公司需要处理的行李规模也随之扩大。尽管行李处理技术持续进步，但如操作失误、协调不当等问题仍然使得行李处理异常（Baggage Mishandling）时有发生。这一问题不仅影响旅客的出行体验，也会增加航空公司的运营及赔偿成本。根据 SITA 发布的《Baggage IT Insights 2026》，2025 年全球约有 2,400 万件行李发生处理异常，造成约 63 亿美元的行业损失，平均每件异常行李就要消耗约 260 美元 [1] 的处理成本。这些数据表明，行李异常是航空公司需要面对和处理的重要问题之一。

传统的航空行李追踪主要依赖条形码扫描及人工记录等方式来追踪行李和保证安全性。然而，这类方式容易受到多种现实制约因素的影响，例如条形码损坏、人工效率较低、信息记录错误等 [2, 3]。为改善这些问题，航空公司及机场逐步引入自动化分拣、RFID（Radio Frequency Identification）及实时行李追踪等技术，以提高行李识别和处理效率。相关技术的发展也得到了国际团体，如国际航空运输协会（IATA）等机构的支持 [3, 4]。

然而，在不断改善现有的行李处理流程的同时，如何评估未来的行李异常风险、如何应对异常发生后的经济损失以及如何安排受影响的旅客等，都是航空公司需要考虑的重要议题。对于受影响的旅客，行李延误或丢失可能带来额外各项支出。这些旅客在行李异常后产生的额外经济保障需求为航空公司设计行李保障产品提供了现实动机，航空公司可以通过提供可选的经济保障，向那些因经历行李异常而产生不便的旅客做出赔付，随后旅客可利用这些津贴购买临时所需的衣物、个人用品，或支付因行李异常产生的其他合理支出，从而减轻额外经济负担，改善出行体验。同时，在合理定价和成本控制的前提下，这类产品也可能为航空公司带来额外收入，从而兼顾旅客保障需求与企业盈利的双重目标。

因此，对于这类产品，其定价需要考虑行李异常的发生风险、赔付金额及旅客需求等综合因素。而在这些因素中，风险发生的概率将直接影响预期的赔付成本。这使得利用航空运营数据预测未来风险，并将预测结果应用于保障产品的定价与盈利能力分析成为一个值得探索的方向。

为此，我们提出一套结合机器学习风险预测与概率保险定价的行李风险管理框架，并以国泰航空（Cathay Pacific）作为拟议应用对象。该框架利用历史航空运营数据预测未来月份的行李异常率，再结合索赔概率、旅客购买需求及经营成本，设计不同保障等级的额外行李保障产品。通过预测模型比较、多情景优化及 Monte Carlo Simulation，评价风险预测方法的表现与保障方案的财务可行性。

2. Methods

为应对航空运输中的行李处理异常问题，我们提出一套行李风险管理框架。该框架由一款行李异常风险预测模型和一款保险定价模型组成，旨在通过风险预测与额外经济保障，减轻行李异常对旅客及航空公司造成的影响。

2.1 Data Collection

该报告使用美国航空运输统计局（BTS）公布的行李处理记录作为原始信息 [5]，通过结合航班延误、客运量、运力及机场规模等运营数据，为风险预测模型提供输入。

考虑到 2019 年前后该机构记录行李统计口径的变化，我们仅保留 2019 年起实际运营承运人的记录，并将各航空公司的原始数据按月份进行整合，避免单位和记录上的不一致 [5]。在训练中，我们使用“月度行李异常率“作为预测目标，其具体设计如下：

$$r_{i,t} = \frac{1000 M_{i,t}}{B_{i,t}} \tag{1}$$

其中，$r_{i,t}$ 为航空公司 i 在月份 t 的行李异常率，单位为件／千件装载行李；$M_{i,t}$ 为航空公司 i 在月份 t 的异常行李数量，$B_{i,t}$ 为同期装载行李数量。

在完成数据清洗和时间对齐后，我们进一步提取历史异常率、运营表现及运输规模等特征，并以航空公司 DOT 标识、年份和月份作为唯一索引，将不同来源的数据整理为统一的预测数据集。随后，我们结合历史异常率的均值、波动及季节性变化与航班延误、客运需求和机场规模等信息，共同构成模型的输入特征，最终形成一个包含 1,226 条样本和 30 个核心特征类别的预测数据集。

2.2 Forecasting Model

我们使用 Light Gradient Boosting Machine（LightGBM）作为主要预测方法 [6]，通过综合历史异常表现、航空运输规模及运营环境等变量，使模型能够学习不同特征之间可能存在的非线性关系。

为了适应航空运输环境随时间发生的变化，我们采用扩展窗口训练（Expanding-Window Training），逐月使用此前的运营数据更新模型，并通过非对称平方损失函数，对高估异常率施加更高惩罚。

$$L_i = \frac{1}{2} w_i \left[a \max(r_i - \hat{r}_i, 0)^2 + b \max(\hat{r}_i - r_i, 0)^2 \right] \tag{2}$$

其中，L_i 为单个样本的损失，r_i 和 $\hat{r}_i$ 分别为实际与预测异常率，w_i 为样本权重，a 和 b 用于调整低估与高估的惩罚程度。

在预测流程中，模型还会将下一月的装载行李数量通过最近一个月与去年同期数据的等权混合进行估计，并结合 LightGBM 预测的异常率共同计算预计异常行李数量:

$$\hat{M}_{i,t+1} = \frac{\hat{r}_{i,t+1} \hat{B}_{i,t+1}}{1000} \tag{3}$$

其中，$\hat{M}_{i,t+1}$ 为航空公司 i 在下一月 $t+1$ 的预测异常行李数量，$\hat{r}_{i,t+1}$ 和 $\hat{B}_{i,t+1}$ 分别为下一月的预测异常率与预测装载行李数量。

2.3 Probability-Based Baggage Protection Scheme

尽管风险预测能够为航空公司提供未来行李异常情况的参考，但它无法消除异常发生后对旅客造成的经济影响。在实际的商业场景中，旅客很可能因为行李异常而遇见各自出行上的不便和困难。因此，我们在风险预测模型的基础上，进一步设计了一套“额外行李保险产品”。该产品包含不同等级的金额津贴，为旅客提供可选择的经济保障。

保障产品分为 Basic、Standard 和 Premium 三个档位，分别对应不同的保费、行李延误津贴和最终丢失补助。每份保障覆盖一名旅客、一件托运行李及一次单程直飞行程。当行李延误超过 12 小时，旅客可获得相应的延时津贴；若行李最终被认定丢失，则此时旅客将按照其所选套餐获得剩余的赔付。

为确定不同保障条件下的赔付成本，平衡成本与盈利，我们将风险预测与保险收益模型相结合，将风险预测结果进一步转化为保险索赔概率。对此，我们采用包含常规风险与特殊情景冲击的情景概率模型，分别估计行李延误与最终丢失的发生概率，将模型定义为:

$$p_i = \frac{\hat{r}_i}{1000}$$

$$Q_{i,\omega} = (1-\pi)\left[1-(1-p_i)^{\rho_\omega}\right] + \pi\left[1-(1-p_i)^{h\rho_\omega}\right] \tag{4}$$

其中，p_i 为预测异常比例，$\hat{r}_i$ 为目标月份的预测异常率；$Q_{i,\omega}$ 为转换后的风险水平，ρ_ω 为情景风险调整系数，π 表示特殊冲击情景的发生概率，h 则为冲击情景下的风险倍率。下标 ω 为经营情景索引，用于区分不同的风险及购买需求假设。

完成风险预测结果的转换后，模型将根据不同保障事件的比例分别计算延误和最终的丢失后索赔概率:

$$q_{D,i,\omega} = Q_{i,\omega} s_{D,\omega}, \qquad q_{L,i,\omega} = Q_{i,\omega} s_{L,\omega} \tag{5}$$

对于保障档位 k，预期赔付成本表示为:

$$\mu_{i,k,\omega} = q_{D,i,\omega} D_k + q_{L,i,\omega} L_k \tag{6}$$

其中，$\mu_{i,k,\omega}$ 为航空公司 i 在情景 ω 下每份档位 k 保单的预期赔付成本；$q_{D,i,\omega}$ 与 $q_{L,i,\omega}$ 分别为延误和最终丢失的索赔概率，$s_{D,\omega}$ 和 $s_{L,\omega}$ 表示发生相关异常后，最终归入延误与丢失结算的条件比例。D_k 与 L_k 为保险套餐对应的补助金额（延误与丢失），这两项参数的最终结算结果互斥。

通过这一方法，我们可以将预测风险与不同保障档位的预期赔付成本联系起来，为后续定价提供依据。

2.4 Insurance Pricing and Optimisation Design

除开保险各档位的预期赔付成本，我们还需要考虑旅客的购买欲望及产品经营成本，以判断保障方案能否实现可持续运营。为此，我们采用多项选择模型（Multinomial Logit Model）[7]，根据保费、保障金额及价格敏感度等参数估计不同档位的购买比例，并结合预测客运规模计算预期销量，最终组成购买概率模型:

对于档位 k，购买概率定义为

$$U_{k,\omega} = \ln \frac{a_{k,0}}{a_{0,0}} - \beta_\omega \ln \frac{P_k}{P_{k,0}} + \gamma_D \ln \frac{D_k}{D_{k,0}} + \gamma_L \ln \frac{L_k}{L_{k,0}} \tag{7a}$$

$$a_{k,\omega} = \frac{\exp(U_{k,\omega})}{1 + \sum_j \exp(U_{j,\omega})} \tag{7b}$$

$$N_{i,k,\omega} = \left\lfloor \eta \hat{V}_i \right\rfloor a_{k,\omega} \tag{7c}$$

其中，$U_{k,\omega}$ 为对应套餐的效用，下标 0 表示参考套餐，β_ω 为价格敏感度，γ_D、γ_L 为保障金额敏感度，分母中的 1 代表不购买保障的选项。

$a_{k,\omega}$ 为情景 ω 下选择档位 k 的购买概率，$a_{k,0}$ 为参考套餐下该档位的购买概率，$a_{0,0}$ 为参考设置下不购买保障的概率；j 遍历全部可购买档位。$P_{k,0}$、$D_{k,0}$ 和 $L_{k,0}$ 分别为参考套餐的保费、延误补助及最终丢失补助。$\hat{V}_i$ 为航空公司 i 的预测航段客运量，η 为潜在投保机会转换比例，$\lfloor \cdot \rfloor$ 表示向下取整。

对于这一保险产品，其利润由收取保费扣除预期赔付、销售及处理等行政费用和系统维护成本综合得到，可以被表示为:

$$\Pi_{i,\omega} = \sum_k N_{i,k,\omega} \left[P_k(1 - f_k) - v_k - \mu_{i,k,\omega} \right] - K_i \tag{8}$$

其中，$\Pi_{i,\omega}$ 为航空公司 i 在经营情景 ω 下的预期利润，$N_{i,k,\omega}$ 为不同情景下的预计销售数量，P_k 为保费，f_k 和 v_k 分别表示比例费用及每份保单的固定费用，K_i 为系统固定成本。

由于旅客购买行为与行李异常风险均可能在特殊因素下发生变化，单一情景下的利润或不足以评价产品的长期可行性。因此，我们通过调整价格敏感度与索赔风险构建了总共六种经营情景，并以最不利情景下的预期利润和利润率作为优化目标，在满足档位价格及保障金额递增、各情景预期利润非负等约束后，利用帕累托最优（Pareto Optimality）筛选保障组合，最终选择兼顾整体收益和利润率的相对最优方案。

3. Experiments

3.1 Forecasting Experiment

在关于预测模型的实验中，我们将 2.1 中提到的数据集按时间顺序划分为 3 类：(i) 训练集，包含 2020 年-2024 年的 957 条样本，模型在这份数据上完成训练；(ii) 验证集，包含 2025 年的 168 条样本；(iii) 滚动测试数据，包含 2026 年 1 月到 8 月共 101 条样本，用来测试模型在不同日期设定下的预测效果。在滚动测试中，我们每月更新一次模型，使用此前月份的全部已知数据预测目标月份的行李异常率。在完成该月的预测与评价后，将其实际数据加入训练集，再进行下一月份的预测。

为了评价模型的预测能力，我们使用加权平均绝对误差（WMAE）和加权均方根误差（WRMSE）衡量行李异常率的预测表现，并使用加权绝对百分比误差（WAPE）评价异常行李数量的预测误差。考虑到不同航空公司的行李运输规模存在差异，异常率评价将采用实际装载行李数量作为权重。

在训练过程中，LightGBM 被设置为 200 棵决策树，学习率为 0.03，最大深度为 3，最多包含 7 个叶节点，最小叶节点样本数为 20，L2 正则化系数设为 1，随机种子为 42，非对称损失函数的低估与高估惩罚权重比为 1:2。

为观察选定模型的表现，我们设置季节性朴素预测（Seasonal Naive）及近期与季节性历史数据等权混合预测作为传统统计基准，并引入 ElasticNet、Poisson GLM、Random Forest、Extra Trees、Histogram Gradient Boosting、对称损失 LightGBM 及 XGBoost 作为其他对比模型。各方法均在相同的 101 条测试记录上完成最终评价，完整比较结果见 Table.1 。

3.2 Insurance Optimisation Experiment

保险收益率的测试基于 2026 年 8 月中 12 家不同航空公司的预测风险与客运规模。在测试中，我们将每家航空公司对应为一个独立的月度经营案例。并以设定的 Basic, Standard, Premium 三档参考套餐作为初始设置，随后分别调整保费与保障金额，观察不同产品设置组合的收益表现。

过程中，我们将风险模型设置为基准与较高风险两种情景，风险调整系数分别设定为 1 和 2，对应的延误结算比例均为 50%，最终丢失比例分别为 5% 和 10%。旅客购买模型的价格敏感度分别设为 1、2 和 3，由此构造出了六种不同的经营情景。我们将潜在投保机会按预测航段客运量的 20% 设置，并将在参考套餐下，Basic、Standard 和 Premium 三类套餐的购买比例分别设为 5%、3% 和 2%，不购买比例 90%。

收益计算中，我们将保险销售及相关管理费用设为保费收入的 25%，并为每份售出的保单额外增加 0.50 美元的处理成本。此外，每家航空公司的月度经营案例均需承担 50,000 美元的系统建设成本分摊及运行费用。保险赔付成本则根据各情景下的索赔概率及保障金额另行计算。通过调整保费与保障金额，我们生成不同的候选套餐，并在满足经营约束后，以最不利情景下的预期利润及利润率为依据选择最终方案。

对于选定的保障方案，我们在六种经营情景与 12 个航空公司案例的各组合下分别进行 30,000 次 Monte Carlo Simulation，以评价索赔波动对盈利表现的影响。此外，我们还通过 108 个额外情景测试购买率和经营成本变化对产品收益表现的影响。

4. Results

4.1 Forecasting Performance

我们引入 ElasticNet、Poisson GLM、Random Forest、Extra Trees、Histogram Gradient Boosting、对称损失 LightGBM 及 XGBoost 作为其他对比模型，并最终根据结果选用非对称 LightGBM 作为最终预测模型。该模型在验证集上的 WMAE 和 WRMSE 分别为 0.4261 和 0.5818，并在最后的测试集上展示了较好效能。完整比较结果见 Table 1。

Table 1: Forecasting Performance from January to August 2026

Model	WMAE ↓	WRMSE ↓	Count WAPE (%) ↓
Seasonal Naive	0.8603	0.9995	20.354
50/50 Historical Blend	0.6972	0.8879	17.977
ElasticNet	0.7165	0.9918	17.742
Poisson GLM	0.7066	1.0043	18.040
Random Forest	0.6596	0.9252	16.665
Extra Trees	0.6782	0.9036	17.155
Histogram Gradient Boosting	**0.6204**	**0.8458**	16.155
LightGBM（对称损失）	0.6475	0.8755	15.969
XGBoost	0.6353	0.8828	16.012
LightGBM（非对称损失，采用模型）	**0.6376**	**0.8866**	**15.836**

进入 2026 年后，Histogram Gradient Boosting 取得了最低的异常率 WMAE 和 WRMSE，而选定的 LightGBM 在异常行李数量预测中取得最低的 WAPE，为 15.836%，较历史混合预测的 17.977% 降低约 2.14 个百分点。两种模型在不同指标

上表现出不同优势：LightGBM 在验证集上的异常率预测优势未延续至 2026 年，但其异常数量预测误差略低于 Histogram Gradient Boosting。我们综合考虑后，最终决定选用 LightGBM 作为模型的主要设计，因为其更稳定的预测优势符合企业可持续和长期发展的目标。



Figure 1: Model performance profiles across statistical and machine-learning methods. Scores are scaled relative to the best result for each metric (100); larger values indicate lower prediction errors.

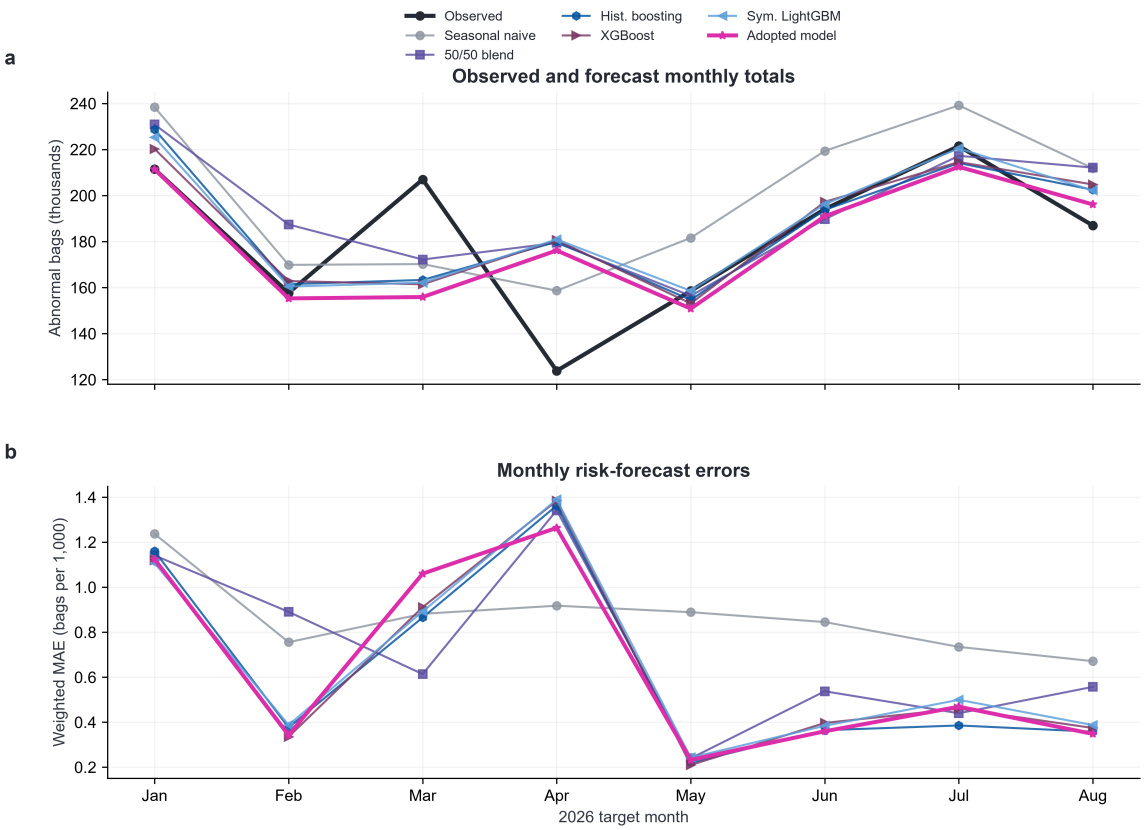


Figure 2: Observed and predicted monthly mishandled baggage totals, and monthly weighted forecasting errors, January–August 2026.

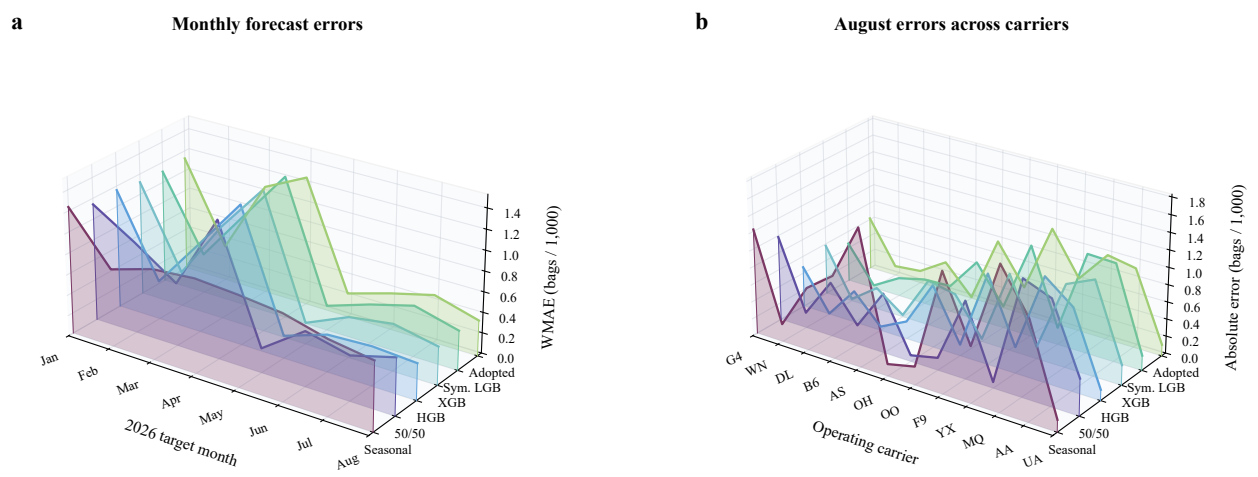


Figure 3: Forecast error comparison: (a) monthly weighted MAE during January–August 2026; (b) absolute errors across 12 carriers in August 2026.

4.2 Baggage Protection Plan Optimisation

我们将 2026 年 8 月的预测结果用于设计保险套餐价格。为实现这一目标，我们在设定的搜索范围内生成了 1,836 组候选方案，并从中选择了 98 组满足经营约束的配置，随后通过计算其帕累托前沿，进一步筛选得到 7 组帕累托前沿方案。按照最不利情景下预期利润与利润率的折中标准进行对比，最终选择如 Table 2 所示的三组套餐。

Table 2: Selected Baggage Protection Plans

Plan	保费（USD）	延误津贴（USD）	最终丢失累计补助（USD）
Basic	3.75	50	300
Standard	6.00	100	600
Premium	11.00	200	1,200

与前文提到的参考套餐相比，Basic 的保费由 3 美元提高至 3.75 美元，Standard 和 Premium 的保费则保持不变。这一组合是在当前候选范围与经营情景中，最能兼顾预期利润规模和利润率的综合性方案。

4.3 Profitability and Sensitivity Analysis

选定套餐后，我们测试了其在不同经营场景下的敏感性。我们选定 2026 年 8 月数据中的 12 家航空公司，并使用它们各自独立的月度案例作为基础，分别计入对应固定成本后，再合计预期利润并计算总体利润率。套餐的具体收益如 Table 3 所示。

Table 3: Financial Performance under Six Operating Scenarios

价格敏感度	风险情景	合计月度预期利润（USD）	模型利润率
$\beta = 1$	基准风险	4,019,839	51.78%
$\beta = 1$	较高风险	3,033,644	39.08%
$\beta = 2$	基准风险	3,819,644	51.62%
$\beta = 2$	较高风险	2,869,604	38.78%
$\beta = 3$	基准风险	3,657,124	51.48%
$\beta = 3$	较高风险	2,736,434	38.52%

结果表明，所选套餐在六种情景下均满足非负预期利润的设计约束。在相同价格敏感度下，较高风险情景的赔付成本增加，预期利润相应下降；随着价格敏感度从 1 增至 3，合计预期利润也有所降低。最不利情景为较高风险且价格敏感度为 3，此

时合计月度预期利润为 2,736,434 美元，模型利润率为 38.52%。

我们还通过设计随机索赔模拟来进一步考察预期利润外的波动。在六种情景与 12 个航司案例的各组模拟中，正利润出现的比例约为 97.80%-100%，展示出了选定保险设计一定的抗风险能力。然而，当我们对购买率和经营成本进行进一步调整后，108 个补充测试案例中有 31 个出现亏损。这说明主要情景下的盈利结果并不能覆盖所有经营条件：即使套餐能够承担设定的索赔成本，购买需求不足或费用增加仍可能使其失去盈利空间。因此，实际销售表现与运营成本是产品试点时需要重点验证的因素。

模拟结果表明，该产品在指定经营情景下具有正的预期经营利润，为其应用至国泰航空的商业可行性提供了初步支持。

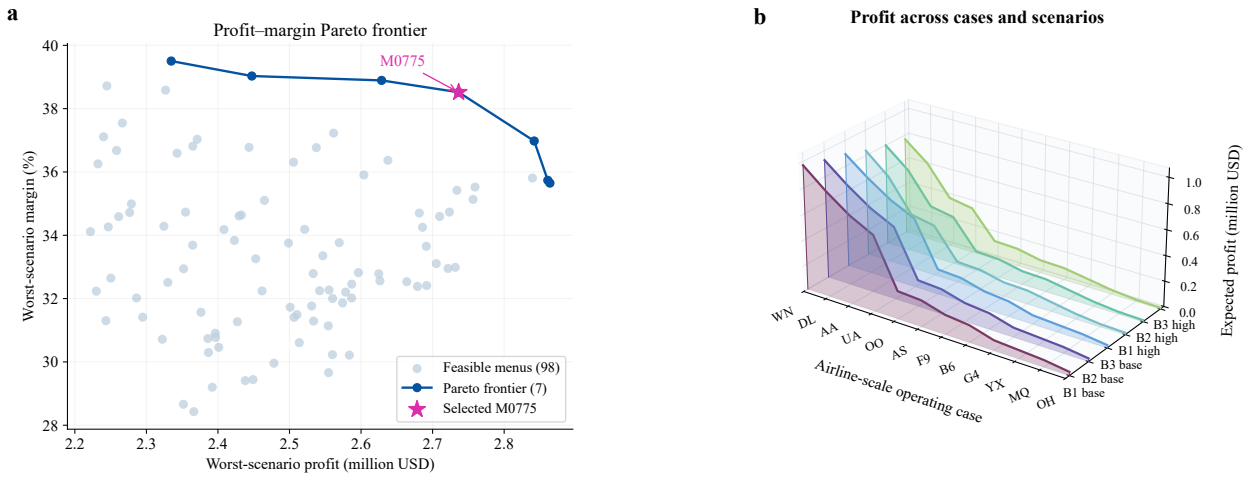


Figure 4: Insurance optimisation and operating outcomes: (a) Pareto frontier and selected menu M0775; (b) expected monthly profit across 12 cases and six scenarios. B1–B3 denote price sensitivity values 1–3; base and high denote the two risk scenarios.

5. Application to Cathay Pacific

根据前述的模型设计和实验结果，我们认为该产品有一定的商业价值，并具备一定的抗风险能力。因此，我们计划为国泰航空引入该款额外行李保障服务（Baggage Protection Scheme），为旅客提供可选的保险套餐，并在行李发生异常后补偿旅客一定的津贴。

5.1 Proposed Product

考虑到不同旅客间行李价值、出行目的以及经济能力等条件的不一致，我们使用分级定价的策略。这一策略可以使旅客根据自身需要和预算选择套餐，避免不同需求的旅客承担统一的额外费用。为此，拟议产品采用 4.2 中设计的 Basic, Standard 和 Premium 三个档位，每个档位分别提供不同程度的延误与最终丢失补助，帮助旅客视情况决定如何购买套餐。

在实际出行中，若旅客的托运行李未能按计划准时抵达目的地，他们可通过国泰的客户服务渠道登记相关情况。随后，旅客的工单会转进对应的服务系统中，开始执行额外保障流程。对于购买了服务，满足保障条件的旅客，该产品将提供以下两种补助：① 当行李延误超过 12 小时未抵达目标地点时，旅客可以获得购买套餐中的“延误津贴”，届时旅客的工单会转入“行李追踪与丢失核实”流程。若在后续处理中，旅客成功取得行李，则服务不会继续推进；② 若最终用户的行李被确认丢失，则服务将进入最终的丢失赔偿流程。我们会按照其所购买档位的“最终丢失累计补助”，将剩余的补助款项结算给客户。

下面我们提供一个案例以便理解：

一名乘坐国泰航空直飞航班、从香港前往伦敦的旅客 A，在购买机票时额外支付了 6 美元，选择了 Standard 行李保障套餐。当他抵达伦敦时，发现自己的托运行李没有一同抵达，于是开始申请额外行李保障服务。在等待超过 12 小时后，他获得了 100 美元的延误津贴，用于购买临时需要的衣物和生活用品。如果行李随后被找回并交付，保障流程便会结束；如果最终确认丢失，他将获得剩余的 500 美元补助，使总补助达到套餐设定的 600 美元。

5.2 Target Market

该产品的目标群体初步选定为：从香港（HKG）出发，搭乘国泰航空直飞航班，并至少托运一件行李的旅客。旅客可以在购买机票时，通过国泰航空的移动应用程序自行选择是否购买该额外保障服务。

我们选择香港作为产品的初期试点市场，主要是考虑到监管要求，协调难度，品牌影响力等综合因素。根据调研，该选址可能带来以下优势：

(i) 监管便利性：现有方案可以将初期销售和保险合作公司安排在相同的司法管辖区内，相比其他面向中国内地或是

(ii) 协调便利性：国泰航空与香港国际机场之间有着长期的运营联系和合作基础 [9]，这对未来可能需要的信息共享

(iii) 有效的当地品牌影响力：国泰航空自1946年在香港成立，长期以来一直是香港本地乃至全球范围内兼具影响力

综上，我们认为现阶段将产品的首要市场目标和群体设置在香港是较为合理且有一定优势的选择。如果产品的反响较好，用户规模达到一定的水平，并带来了可观的商业收入，我们才会考虑推广至中国内地乃至其他更广泛的地区。

5.3 Implementation Plan

为将拟议的行李保障产品投入实际运营，我们计划采用分阶段实施的方式。首先，国泰航空需要与具备相应资质的保险机构确定合作安排，包括产品销售、理赔责任及收益分配方式。同时，我们将利用国泰的历史行李异常与索赔记录重新校准风险模型，并根据实际经营成本调整保障套餐的保费与补助金额。

完成前期准备后，我们计划在符合条件的香港出发直飞航班上开展小规模试点，通过国泰现有的机票预订渠道向旅客提供可选的保障套餐。在试点期间，我们将收集实际购买率、索赔情况、运营成本及旅客反馈，评估产品的经营表现。

根据试点结果，国泰可以进一步调整产品定价、保障金额及销售策略，甚至视情况推出更多可选套餐与商业产品。

6. Conclusion

本报告以国泰航空为拟议应用对象，针对航空运输中的行李处理异常问题提出了一套结合机器学习风险预测与概率保险定价的行李保障方案。通过分析历史航空运营数据，我们建立了基于 LightGBM 的月度行李异常预测模型，并利用多情景优化方法设计了一款额外行李保障产品。报告提出的产品旨在为旅客提供可选的额外经济津贴，在减轻旅客因行李延误或丢失而导致的可能负担的同时，为航空公司探索新的辅助收入来源。实验结果表明，选定模型在异常行李数量预测方面优于传统统计基准，而保障方案在六种主要经营情景下均取得了正的预期利润，表现出一定的商业可行性。不过，鉴于目前的预测模型主要基于美国航空公司的公开运营数据训练，且保险模型设计中部分参数为情景假设，我们认为，未来实际应用时应结合实际情况进一步作验证及分析。

References

[1] SITA, "Tech drove down mishandled bag rates by 23% in 2025, but mishandling still costs the industry $6.3 billion a year," Jun. 29, 2026. [Online]. Available: https://www.sita.aero/about-us/pressroom/news-releases/tech-drove-down-mishandled-bag-rates-by-23-in-2025-but-mishandling-still-costs-the-industry-%246.3-billion-a-year

[2] D. L. Hafilah, A. Cakravastia, Y. Lafdail, and N. Rakoto, "Modeling and Simulation of Air France Baggage Handling System with Colored Petri Nets," *IFAC-PapersOnLine*, vol. 52, no. 13, pp. 2443–2448, 2019. doi: 10.1016/j.ifacol.2019.11.573. Available: https://doi.org/10.1016/j.ifacol.2019.11.573

[3] International Air Transport Association (IATA), *Baggage Tracking —Resolution 753 Implementation Guide*, Issue 4.0, 2023. [Online]. Available: https://www.iata.org/contentassets/d22bcfe86aa54f22a2919b0e4224f68f/reso753-implementation-guide---2023_issue-4.0.pdf

[4] International Air Transport Association (IATA), *Resolution on Radio Frequency Identification (RFID) in Baggage*, 75th Annual General Meeting, Jun. 2, 2019. [Online]. Available: https://www.iata.org/contentassets/638cad2c0eb6464eaa4ae176a2b98bcb/resolution-rfid-agm-2019.pdf

[5] Bureau of Transportation Statistics (BTS), *Technical Reporting Directive No. 30A —Mishandled Baggage and Wheelchairs and Scooters (Amended)*, Dec. 21, 2018, effective Jan. 1, 2019. [Online]. Available: https://www.bts.gov/topics/airlines-and-airports/number-30a-technical-directive-mishandled-baggage-amended-effective-jan

[6] G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

[7] K. E. Train, *Discrete Choice Methods with Simulation*, 2nd ed. Cambridge University Press, 2009. Available: https://doi.org/10.1017/CBO9780511805271

[8] Cathay Pacific Airways Limited, *Sustainability Report 2025*, 2026. [Online]. Available: https://www.cathaypacific.com/content/dam/cx/about-us/sustainability/sustainability-reports/en/cathay-pacific-sustainability-report-2025-en.pdf

[9] Airport Authority Hong Kong, "AA Welcomes the Government's Investment in Support of Cathay Pacific's Recapitalisation Plan," Jun. 9, 2020. [Online]. Available: https://www.hongkongairport.com/en/media-centre/press-release/2020/pr_1451

[10] Marketing-Interactive, "Which brands win Hongkongers' hearts in 2026?," Oct. 2026. [Online]. Available: https://www.marketing-interactive.com/which-brands-win-hkers-hearts-in-2026

[11] Insurance Authority, *Handbook for Key Persons in Control Function for Intermediary Management of Authorized Insurers*, 2026, Section V, "Cross-Border Selling." [Online]. Available: https://www.ia.org.hk/en/legislative_framework/files/Handbook_for_Key_Persons_in_Control_Function_for_Intermediary_Management_of_Authorized_Insurers_2026.pdf